

Sprint Report — Fine-tune & Host LLM (bản rút gọn)

Người thực hiện: Dương Phương Thảo · **Thời gian:** 2 tuần (chốt 06/06/2026) **Dự án:** Fine-tune Qwen2.5-1.5B viết lại câu lệnh hội thoại tiếng Việt cho trợ lý trong xe

Tổng quan

Dạy mô hình nhỏ (**Qwen2.5-1.5B**) đọc hội thoại nhiều lượt rồi **viết lại thành một câu lệnh ngắn gọn, đủ ý**. Đây là lần đầu mình làm trọn vòng đời fine-tune: chuẩn bị dữ liệu → huấn luyện → host vLLM → đo lường → cải thiện.

Mình đã làm gì

- Dữ liệu:** sinh **20.000 mẫu** bằng template, chia **train 16.001 / valid 2.000 / test 1.999**; vá thêm 1.000 mẫu thành train_v2 (17.001). Dùng Frontier Models (ChatGPT, Gemini, Claude, Grok trên browser) tạo riêng một **benchmark khó 1.044 mẫu** để chấm điểm (8 dạng dễ sai: đại từ, ngữ cảnh nhiễu, slot rải nhiều lượt, phủ định...) — bộ này tách biệt, không cho mô hình thấy lúc train.
- Fine-tune:** dùng **LoRA/QLoRA (4-bit)** — như dán một "miếng vá" ~50MB lên mô hình gốc, chạy được trên 1 GPU T4 16GB miễn phí của Kaggle.
- Host & demo:** dựng **vLLM** (API chuẩn OpenAI) + **ngrok** để truy cập từ xa; làm UI **Gradio** bấm-là-chạy, nạp sẵn mẫu test thật.
- Đo lường:** pipeline benchmark dùng **LLM-judge** chấm 4 tiêu chí (ý định, đủ slot, không bịa, giữ phủ định); tách rời bước predict/judge và giữ một giám khảo cố định.
- Cải thiện:** lập chu trình **đo → tìm điểm yếu → vá đúng chỗ → train lại → đo lại** (2 vòng).

Kết quả chính

Chỉ số (trên benchmark 1.044 mẫu)	Base	LoRA v1.0	LoRA v2.0
Command Accuracy (chính)	52.8%	65.9%	65.6%
Intent Accuracy	81.0%	88.5%	88.7%
Slot Completeness	58.7%	70.9%	71.1%
Multi-turn slot (điểm yếu nhất)	13.5%	52.8%	57.1%
Phủ định (đã hiệu chỉnh)	88.2%	81.5%	81.5%

- Fine-tune giúp hơn base **~+13 điểm** ở chỉ số chính; cách biệt lớn nhất ở **multi-turn slot** (13.5% → 52.8%).

Đã cải thiện gì sau khi vá dữ liệu (LoRA v1.0 → v2.0, thêm ~1.000 mẫu):

Dạng câu khó	Trước vá	Sau vá	Thay đổi
multi_turn_slot (mục tiêu)	52.8%	57.1%	+4.3 ✓
implicit_reference (hưởng lợi)	65.9%	69.0%	+3.1 ✓
Command Accuracy tổng	65.9%	65.6%	-0.3 (phẳng)

- Bản vá **đánh trúng đích** mà tổng thể không hỏng.
- Mô hình 1.5B hay "**nén**" **quá tay** → rút mệnh đề phủ định; xác nhận đây là **lỗi thật (~-6.7đ)**, **không phải lỗi đo**.

Mình học được gì

- **Kỹ năng mới (lần đầu làm):** fine-tune model trên **Kaggle**; fine-tune bằng **LoRA** với **LLaMA Factory**; **research để chọn model phù hợp** cho tác vụ; và **research các metric** để biết đo cái gì cho đúng.
- **Prompt phải thật chi tiết:** viết prompt cho **judge model** và **base model** càng rõ ràng, càng nhiều **few-shot** thì kết quả càng chuẩn — đây là đòn bẩy lớn mà ít tốn công.
- **Mượn sức model lớn để nâng model nhỏ:** dùng **model mạnh tạo few-shot/dữ liệu chất lượng** rồi cho **model nhỏ học và làm theo** — cách hiệu quả để model nhỏ làm tốt hơn nhiều.
- **Đo lường đúng quan trọng ngang việc train**
- **Chẩn đoán trước khi vá:** xác nhận dữ liệu sạch trước, nên biết lỗi nằm ở *hành vi mô hình*.
- **Vá hẹp, đúng chỗ thắng nhờ data bù** — chất lượng hơn số lượng.
- **Hạ tầng cũng là việc:** nâng context 2048→8192, tách predict/judge, cho resume khi timeout, giữ giám khảo cố định để so sánh công bằng.
- **Mô hình nhỏ có "trần" năng lực** — đôi khi giải pháp là mô hình lớn hơn, không phải thêm data.

Bước tiếp theo

Thêm **patch B4** dạy mô hình giữ mệnh đề phủ định + chi tiết quan trọng, train lại; nếu phủ định vẫn kẹt thì cân nhắc nâng lên **Qwen2.5-3B**.